

# MA - curs 3

## CAP. 2., §4 (continuare)

### Caracteristici numerice (statistice) ale v.a. 1D

#### 4.5. Inegalități legate de medie și dispersie

##### 4.5.1. Inegalitatea lui Schwarz (p. 84-85)

$$\exists M(x^2), \exists M(y^2) \Rightarrow |M(xy)| \leq \sqrt{M(x^2)M(y^2)}$$

obs.  $y = 1 \Rightarrow xy = x, M(y) = 1 \Rightarrow \boxed{|M(x)| \leq \sqrt{M(x^2)} \Leftrightarrow M^2(x) \leq M(x^2)}$

4.5.2.

$$\left\{ \begin{array}{l} X = \begin{pmatrix} x_i \\ p_i \end{pmatrix}_{i \in I} \Rightarrow \left( \sum_{i \in I} p_i x_i \right)^2 \leq \sum_{i \in I} x_i^2 p_i \\ X \text{ v.a. 1D cont} \\ f(x) \rightarrow p \, d f \end{array} \right\} \Rightarrow \left( \int_{-\infty}^{\infty} x f(x) dx \right)^2 \leq \int_{-\infty}^{\infty} x^2 f(x) dx$$

##### 4.5.2. Inegalitatea lui Cebîșev (Cebyshev, Tchebycheff)

$$X \text{ v.a. 1D}; \varepsilon > 0 \Rightarrow \begin{cases} P(|X - M(X)| < \varepsilon) \geq 1 - \frac{D^2(X)}{\varepsilon^2} \\ P(|X - M(X)| \geq \varepsilon) \leq \frac{D^2(X)}{\varepsilon^2} \end{cases}$$

Dem. fîc  $m = M(X)$ . Amem:  $|x - m| \geq \varepsilon \Leftrightarrow (x - m)^2 \geq \varepsilon^2 \Leftrightarrow 1 \leq \frac{(x - m)^2}{\varepsilon^2} \quad (1)$

Obținem:  $P(|X - m| \geq \varepsilon) = \int_{|x-m| \geq \varepsilon} f(x) dx = \int_{|x-m| \geq \varepsilon} 1 \cdot f(x) dx \stackrel{(1)}{\leq}$

$$\stackrel{(1)}{\leq} \int_{|x-m| \geq \varepsilon} \frac{(x-m)^2}{\varepsilon^2} f(x) dx = \frac{1}{\varepsilon^2} \int_{|x-m| \geq \varepsilon} (x-m)^2 f(x) dx \leq \frac{1}{\varepsilon^2} \int_{-\infty}^{\infty} (x-m)^2 f(x) dx = \frac{1}{\varepsilon^2} D^2(X).$$

obs.  $|x - m| \geq \varepsilon \Leftrightarrow x - m \leq -\varepsilon$  sau  $x - m \geq \varepsilon \Leftrightarrow x \in (-\infty, m - \varepsilon) \cup (m + \varepsilon, \infty)$

4.5.3. Regula celor trei sigma

Pornim de la inegalitatea lui Chebyshev  $P(|X-m| < \varepsilon) \geq 1 - \frac{D^2(X)}{\varepsilon^2}$


și luăm  $\varepsilon = 3\sigma$ , unde  $\sigma = \sigma(X) = \sqrt{D^2(X)}$ , deci  $D^2(X) = \sigma^2 \Rightarrow$

$$\Rightarrow P(|X-m| < 3\sigma) \geq 1 - \frac{\sigma^2}{9\sigma^2} \Rightarrow \underline{P(|X-m| < 3\sigma) \geq \frac{8}{9}} \quad \Rightarrow$$

$$\Rightarrow \underline{P(X \in (m-3\sigma, m+3\sigma)) \geq \frac{8}{9} \approx 0.9}$$

Am utilizat  $|X-m| < 3\sigma \Leftrightarrow -3\sigma < X-m < 3\sigma \Leftrightarrow X \in (m-3\sigma, m+3\sigma)$

„Majoritatea” valorilor unei v.a. 1D (discrete sau continue) sunt situate în intervalul  $(m-3\sigma, m+3\sigma)$ , centrat în valoarea medie  $m = M(X) = E(X)$



4.5.4. OBS. Analog cu 4.5.3., luăm  $\varepsilon = n\sigma$ ;  $n \geq 1 \Rightarrow$

$$\Rightarrow P(|X-m| < n\sigma) \geq 1 - \frac{\sigma^2}{n^2\sigma^2} \Rightarrow$$

$$\Rightarrow \underline{P(X \in (m-n\sigma, m+n\sigma)) \geq 1 - \frac{1}{n^2}}$$

Așadar, probabilitatea ca  $X \in (m-n\sigma, m+n\sigma)$  crește odată cu  $n$ , ceea ce justifică faptul că  $\sigma = \sqrt{D^2(X)}$  este o măsură a impreciziei valorilor v.a.  $X$  în jurul valorii medii  $m$ .

§4.6. Alte caracteristici statistice ale unei v.a. 1D (p.87-88-89)

4.6.1. Asimetria ~~As~~  $As(X) = \frac{\mu_3(X)}{\sigma^3(X)}$

4.6.2. Excesul  $Ex(X) = \frac{\mu_4(X)}{\sigma^4(X)} - 3$

4.6.3. Moda, notată  $Mo(X)$ , este abscisa punctului de maxim al p.m.f. (pentru v.a. 1D discrete), respectiv al p.d.f. (pentru v.a. 1D continue)



OBS.  $X = \begin{pmatrix} x_i \\ p_i \end{pmatrix}_{i \in I}$ ;  $p_n = \max\{p_i : i \in I\} \Rightarrow M_o(X) = x_n$

4.6.4. Mediana, notată  $Me = Me(X)$ , este definită prin dubla inegalitate:  $F(Me) \leq \frac{1}{2} \leq F(Me+0) \Leftrightarrow$   
 $\Leftrightarrow P(X < Me) \leq \frac{1}{2} \leq P(X \leq Me)$

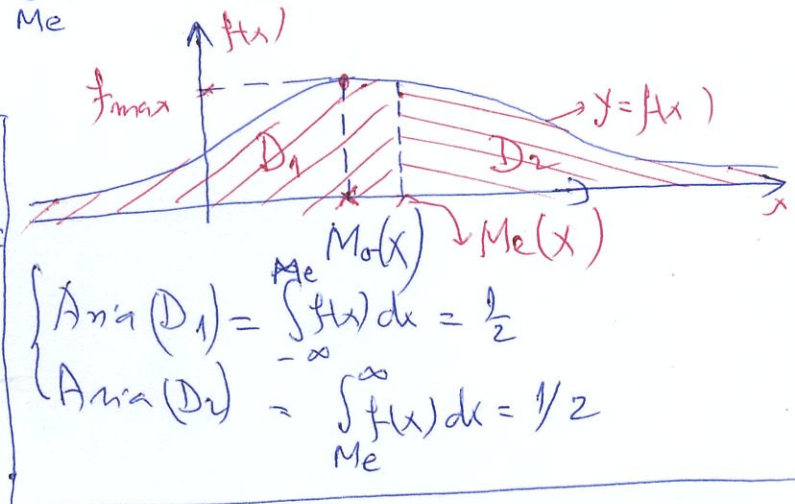
OBS.1 Dacă  $F$  este o funcție continuă, atunci  $F(Me) = \frac{1}{2}$ ,  
 deci  $Me = Me(X)$  este soluția ecuației  $F(x) = \frac{1}{2}$ .

OBS.2 Dacă  $X$  este v.a. continuă, atunci  $Me = Me(X)$  se definește  
 prin:  $\int_{-\infty}^{Me} f(x) dx = \frac{1}{2} \Leftrightarrow \int_{Me}^{\infty} f(x) dx = \frac{1}{2}$ .

Interpretări geometrice

OBS.3 X v.a. discretă  $X: \begin{pmatrix} x_i \\ p_i \end{pmatrix}_{i \in I}$

$$\sum_{\substack{x_i < Me \\ \uparrow \\ x_i < Me}} p_i \leq \frac{1}{2} \leq \sum_{\substack{x_i \leq Me \\ \uparrow \\ x_i \leq Me}} p_i$$



## § 4.7. Entropia

Noțiune introdusă de Shannon (1948).  
Entropia cuantifică cantitatea de informație relativă de o v.a.  
 sau incertitudinea relativă la rezultatul unui experiment aleator.

4.7.1. Def. Să  $X: \begin{pmatrix} x_1 & x_2 & x_3 & \dots & x_n \\ p_1 & p_2 & p_3 & \dots & p_n \end{pmatrix}$  o v.a. 1D simplă

$$H(X) = H(p_1, p_2, p_3, \dots, p_n) = \sum_{i=1}^n p_i \log_2 \left( \frac{1}{p_i} \right) = - \sum_{i=1}^n p_i \log_2(p_i)$$

4.7.2. Unitate de măsură: bit

OBS.  $\log_2 \rightarrow \ln \Rightarrow$  u.m.: nat  
 $\log_2 \rightarrow \lg \Rightarrow$  u.m.: hartley

4.7.3. Obs. 1  $H$  depinde de  $(n-1)$  variabile  $p_1, p_2, p_3, \dots, p_{n-1}$ , deoarece  $p_1 + p_2 + p_3 + \dots + p_n = 1$ , deci  $p_n = 1 - p_1 - \dots - p_{n-1}$ .

Obs. 2  $\tilde{X}: \begin{pmatrix} \log_2(1/p_i) \\ p_i \end{pmatrix} \Rightarrow H(\tilde{X}) = H(X) = M(\tilde{X})$

Interpretând  $\log_2(1/p_i)$  drept conținutul de informație al evenimentului  $(X=x_i)$ , entropia reprezintă informația medie furnizată de v.a.  $\tilde{X}$ .

4.7.4. Exemple  $X: \begin{pmatrix} 0 & 1 \\ p & 1-p \end{pmatrix}, p \in (0,1)$


R. Amem  $H(X) = H(p) = -p \log_2 p - (1-p) \log_2 (1-p)$

$$H'(p) = -\log_2 p - p \frac{1}{p} \cdot \frac{1}{\ln 2} + \log_2 (1-p) - (1-p) \cdot \frac{-1}{1-p} \cdot \frac{1}{\ln 2} = \log_2 \frac{1-p}{p}$$

$$H'(p) = 0 \Rightarrow \frac{1-p}{p} = 1 \Rightarrow p = 1/2; \quad H(1/2) = \frac{1}{2} + \frac{1}{2} = 1$$

$$H''(p) = -\frac{1}{p} \cdot \frac{1}{\ln 2} - \frac{1}{1-p} \cdot \frac{1}{\ln 2} = -\frac{1}{\ln 2} \cdot \frac{1}{p(1-p)} < 0 \Rightarrow H \text{ concavă}$$

|         |           |     |           |
|---------|-----------|-----|-----------|
| $p$     | 0         | 1/2 | 1         |
| $H(p)$  | $+\infty$ | 1   | $-\infty$ |
| $H'(p)$ | 0         | 1   | 0         |



4.7.5. Proprietăți (i)  $H$  continuă în raport cu  $p_1, p_2, p_3, \dots, p_n$   
 (ii)  $H(p_1, p_2, p_3, \dots, p_n) \leq \log_2 n$

Amem  $H(p_1, p_2, p_3, \dots, p_n) = \log_2 n \Leftrightarrow p_i = \frac{1}{n} \Leftrightarrow X: \begin{pmatrix} 1 & 2 & \dots & n \\ \frac{1}{n} & \frac{1}{n} & \dots & \frac{1}{n} \end{pmatrix}$

Lemma. Ineq. Jensen  $\left\{ \begin{array}{l} f \text{ concavă} \\ f: \mathbb{R} \rightarrow \mathbb{R} \end{array} \right. \Rightarrow \sum_{i=1}^n p_i f(x_i) \leq f\left(\sum_{i=1}^n p_i x_i\right),$   
 $\forall p_i \in (0,1), \sum_{i=1}^n p_i = 1, \forall x_i \in \mathbb{R}$

Luăm  $f(t) = \log_2 t \Rightarrow f'(t) = \frac{1}{\ln t} \cdot \frac{1}{t} \Rightarrow f''(t) = -\frac{1}{\ln t} \cdot \frac{1}{t^2} \leq 0 \Rightarrow$

$\Rightarrow f$  concavă. Deci  $\sum_{i=1}^n p_i \log_2 \frac{1}{p_i} \leq f\left(\sum_{i=1}^n p_i \frac{1}{p_i}\right) \Rightarrow H(X) \leq f(n) = \log_2 n$   
 Luăm  $t_i = \frac{1}{p_i}$



## §4.8. Funcția de fiabilitate

4.8.1. Def. Fie  $T$  v.a. 1D, având funcția de repartiție

$$F(t) = F_T(t) = P(T \leq t), t \in \mathbb{R}$$

Funcția  $R = R_T: \mathbb{R} \rightarrow [0,1]$ ,  $R(t) = P(T > t)$ ,  $\forall t \in \mathbb{R}$ ,  
se numește funcția de fiabilitate asociată v.a.  $T$

4.8.2. Ob.  $R(t) = 1 - P(T \leq t) \Rightarrow$   $R(t) = 1 - F(t+0)$

Dacă  $F$  continuă  $\Rightarrow$   $R(t) = 1 - F(t)$

4.8.3. Denunț echivalent: siguranța în funcționare; funcția de ~~supraviețuire~~  
de supraviețuire

4.8.4. Interpretare în Tema Fiabilității Dacă v.a.  $T$  descrie  
(repetitiv) durata de viață sau de supraviețuire a unui sistem  
(sau ansamblu), atunci  $R(t)$  reprezintă probabilitatea de bună  
funcționare până la momentul  $t$  a ~~un~~ sistemului (ansamblu)  
respectiv, adică ~~probabilitatea~~ probabilitatea ca sistemul să NU se  
defecteze până la momentul  $t$ .

4.8.5. Ob. Aduntem  $R(0) = 1$ , adică sistemul este în stare  
de bună funcționare la primire.

## §4.9. Rata de defectare (Rata de hazard)

Ne situăm în ipotezele de la §4.8. notați  $r(t) = r_T(t)$ ,  $t > 0$

4.9.1. Def. Rata de defectare (hazard) este legată de probabilitatea ca  
sistemul să se defecteze în momentul imediat următor lui  
 $t$ , adică în intervalul  $(t, t+dt)$ , CONDITIONAT de faptul că  
NU s-a defectat până la momentul  $t$ .

Din p.v. matematic, rata de hazard este o funcție  $r: \mathbb{R} \rightarrow \mathbb{R}_+$

### 4.9.2. Formule de calcul

Soit  $F(t)$  fonction de répartition,  $f(t)$  p.d.f., aléatoire v.a. 1D continue  $T$ .  
Admettons  $F$  continue  $\Rightarrow R(t) = 1 - F(t) \Rightarrow R'(t) = -F'(t) = -f(t)$ .

$$(i) R(t) = \frac{f(t)}{R(t)} \quad ; \quad (ii) R(t) = \frac{f(t)}{1-F(t)} \quad \left[ \begin{array}{l} R(t) = P(T > t) \\ R(t) = 1 - F(t) \end{array} \right]$$

$$(iii) R(t) = \frac{F'(t)}{1-F(t)} = \frac{f(t)}{R(t)} \quad ; \quad (iv) R(t) = -\frac{R'(t)}{R(t)} = \frac{F'(t)}{R(t)}$$

$$(v) R(t) = \exp\left(-\int_0^t r(z) dz\right) = e^{-\int_0^t r(z) dz}$$

Dém.  $R(t) = \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t \mid T > t)}{\Delta t} =$

$$= \lim_{\Delta t \rightarrow 0} \frac{P(T \in [t, t + \Delta t) \cap (t, \infty))}{P(T > t) \cdot \Delta t} = \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t)}{P(T > t) \Delta t} =$$

$$= \frac{1}{P(T > t)} \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t)}{\Delta t} = \frac{1}{R(t)} \lim_{\Delta t \rightarrow 0} \frac{F(t + \Delta t) - F(t)}{\Delta t} =$$

$$= \frac{1}{R(t)} F'(t) = \frac{f(t)}{R(t)} //$$

### § 4.10. Fonction caractéristique (p. 92-95)

4.10.1. Définition Soit  $X$  v.a. 1D. Fonction  $\varphi = \varphi_X : \mathbb{R} \rightarrow \mathbb{C}$ ,

$$\varphi(t) = M(e^{jtx}) = E(e^{jtx})$$

se nomme fonction caractéristique associée v.a.  $X$ .

(i)  $X$  est v.a. 1D discrète ;  $X = \begin{pmatrix} x_n \\ p_n \end{pmatrix}_{n \in I} \Rightarrow \varphi(t) = e^{jtx} ; \begin{pmatrix} e^{jtx_n} \\ p_n \end{pmatrix}_{n \in I}$

$$\Rightarrow \varphi(t) = \sum_{n \in I} p_n e^{jtx_n} = \sum_{n \in I} p_n \exp(jtx_n)$$

(ii)  $X$  est v.a. 1D continue ;  $f(x) = \text{pdf}(X) \Rightarrow$

$$\Rightarrow \varphi(t) = \int_{-\infty}^{\infty} f(x) e^{jtx} dx$$



4.10.2. Proprietăți ale funcției caracteristice:

(i)  $\varphi(0) = 1$  ; (ii)  $|\varphi(t)| \leq 1$  ; (iii)  $\varphi(-t) = \overline{\varphi(t)}$

(iv) Calcul momente, valori medii, dispersie (varianță)

$$M_n(X) = j^{-n} \varphi^{(n)}(0)$$

$$M_1(X) = E(X) = j^{-1} \varphi'(0) ; M_2(X) = j^{-2} \varphi''(0) = -\varphi''(0)$$

$$D^2(X) = \text{Var}(X) = M_2(X) - M_1^2(X) = -\varphi''(0) + (\varphi'(0))^2$$

4.10.3. Exemplu: Legea exponențială negativă  $T$

$$f(x) = \begin{cases} 0, & x < 0 \\ \lambda e^{-\lambda x}, & x \geq 0 \end{cases} ; \lambda > 0 \text{ dat}$$

Se cere (i)  $\varphi(t)$ ; (ii)  $M(T) = E(T)$  ; (iii)  $D^2(T) = \text{Var}(T)$

(iv)  $R_T(t)$ ; (v)  $\lambda_T(t)$

R. (i)  $\varphi(t) = \int_{-\infty}^{\infty} f(x) e^{jtx} dx = \int_0^{\infty} \lambda e^{-\lambda x} e^{jtx} dx = \lambda \int_0^{\infty} e^{-(\lambda - jt)x} dx =$   
 $= \lambda \mathcal{L}\{1\}(\lambda - jt) = \lambda \cdot \frac{1}{\lambda - jt} = \frac{\lambda}{\lambda - jt} = \frac{\lambda(\lambda + jt)}{\lambda^2 + t^2}$

(ii)  $M(T) = -j^{-1} \varphi'(0) = -\frac{1}{j} \left. \frac{\lambda j}{(\lambda - jt)^2} \right|_{t=0} = \frac{1}{\lambda^2} = \frac{1}{\lambda}$

(iii)  $\varphi''(t) = \left( \frac{\lambda j}{(\lambda - jt)^2} \right)' = \frac{2\lambda j^2}{(\lambda - jt)^3} \Rightarrow D^2(T) = \text{Var}(T) = -\varphi''(0) + (\varphi'(0))^2 =$   
 $= \frac{-2\lambda}{\lambda^3} + \frac{1}{\lambda^2} = -\frac{2}{\lambda^2} + \frac{1}{\lambda^2} = -\frac{1}{\lambda^2} \Rightarrow D^2(T) = \frac{1}{\lambda^2} \Rightarrow \sigma(T) = \frac{1}{\lambda} = M(T)$

(iv)  $R(t) = 1 - F(t)$  ;  $F(t) = \int_{-\infty}^t f(x) dx = \begin{cases} 0, & t < 0 \\ \lambda \int_0^t e^{-\lambda x} dx, & t \geq 0 \end{cases}$   
 $= \begin{cases} 0, & t < 0 \\ \lambda \cdot \frac{e^{-\lambda x}}{-\lambda} \Big|_0^t, & t \geq 0 \end{cases} = \begin{cases} 0, & t < 0 \\ 1 - e^{-\lambda t}, & t \geq 0 \end{cases} \Rightarrow R(t) = \begin{cases} 1, & t < 0 \\ e^{-\lambda t}, & t \geq 0 \end{cases}$

(v)  $\lambda(t) = \frac{f(t)}{R(t)} = \begin{cases} 0, & t < 0 \\ \lambda, & t \geq 0 \end{cases} \Rightarrow \lambda(t) = \lambda = \text{cte}, \forall t \geq 0$

Ans. Reciproc, dacă o v.a. ID are rata de defectare constantă, atunci  $T$  urmează o lege de probabilitate exponențială negativă (p. 146-147)



## §5. Variabile alatoare multi-dimensionale (2D, 3D, nD)

### §5.1. Definiții. Formule de bază (p. 39-50)

1. Def.  $(E, \mathcal{F}, P)$  câmp de probabilități;  $n \geq 1$ ;  $X_1, X_2, X_3, \dots, X_n$  v.a. 1D.

Funcția  $V = (X_1, X_2, X_3, \dots, X_n): E \rightarrow \mathbb{R}^n$ ,

$V(\omega) = (X_1(\omega), X_2(\omega), X_3(\omega), \dots, X_n(\omega)), \omega \in E$ ,

n variabile alatoare n-dimensionale sau vector alator n-dimensional, notată v.a. nD, asociată câmpului  $(E, \mathcal{F}, P)$

(i)  $n=2$   $V = (X, Y)$  v.a. 2D

(ii)  $n=3$   $V = (X, Y, Z)$  v.a. 3D

2. Funcția de repartiție  ~~$f$~~

$F = F_V: \mathbb{R}^n \rightarrow [0, 1]$ ;  $F(x_1, x_2, x_3, \dots, x_n) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n)$

(i)  $n=2$   $F(x, y) = P(X \leq x, Y \leq y)$

(ii)  $n=3$   $F(x, y, z) = P(X \leq x, Y \leq y, Z \leq z)$

3. Proprietăți, ( $n=2$ ) (i)  $F(x, -\infty) = F(-\infty, y) = F(-\infty, -\infty) = 0$ ;  $F(\infty, \infty) = 1$

(ii)  $P(a \leq X < b; c \leq Y < d) = F(b, d) - F(a, d) - F(b, c) + F(a, c)$

4. V.a. 2D discrete  $X: \left( \begin{smallmatrix} x_i \\ p_i \end{smallmatrix} \right)_{i \in I}$ ;  $Y: \left( \begin{smallmatrix} y_j \\ q_j \end{smallmatrix} \right)_{j \in J}$ ;  $\sum_{i \in I} p_i = \sum_{j \in J} q_j = 1$

$V = (X, Y) \neq \left( \begin{smallmatrix} (x_i, y_j) \\ p_{ij} \end{smallmatrix} \right)_{(i,j) \in I \times J}$ ;  $p_{ij} = P(X = x_i, Y = y_j)$

5. pdf 2D

$f: \mathbb{R}^2 \rightarrow \mathbb{R}$

(i)  $f$  integrabil pe  $\mathbb{R}^2$   
 (ii)  $f(x, y) \geq 0, \forall (x, y) \in \mathbb{R}^2$   
 (iii)  $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$

6. V.a. 2D continue  $V = (X, Y)$ ;  $\exists$  pdf  $f(x, y)$  a.v.

$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(t, s) dt ds, \forall (x, y) \in \mathbb{R}^2$

7. Proprietăți v.a. 2D continue

(i)  $f(x, y) = \frac{\partial^2 F}{\partial x \partial y}(x, y)$   
 (ii)  $H \subseteq \mathbb{R}^2 \Rightarrow P((X, Y) \in H) = \iint_H f(x, y) dx dy$



## §5.2. Caracteristici numerice (statistice) ale v.a. 2D (p. 99-101)

$V = (X, Y)$ ;  $m, n \in \mathbb{N}$ ;

1. Def. Momentul de ordin  $(m, n)$   $M_{m,n}(X, Y) = M(X^m Y^n)$

2. Cuplul discret  $X: \left( \begin{smallmatrix} x_i \\ p_i \end{smallmatrix} \right)_{i \in I}$ ;  $Y: \left( \begin{smallmatrix} y_j \\ q_j \end{smallmatrix} \right)_{j \in J}$ ;  $\sum_{i \in I} p_i = \sum_{j \in J} q_j = 1$

$$M_{m,n}(X, Y) = \sum_{i \in I} \sum_{j \in J} x_i^m y_j^n p_{ij}; \text{ unde}$$

$p_{ij} = P(X = x_i; Y = y_j)$ . Dacă  $X, Y$  indep.  $\Rightarrow p_{ij} = p_i q_j$ .

3. Cuplul continuu  $f(x, y)$  p.d.f. pentru v.a.  $V = (X, Y)$

$$M_{m,n}(X, Y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x^m y^n f(x, y) dx dy$$

4. Obs. Admitem  $X^0 = Y^0 = 1 \Rightarrow M_{m,0}(X, Y) = M_m(X)$

$$M_{0,n}(X, Y) = M_n(Y)$$

4. Momente centrale de ordin  $(m, n)$   $m_1 = M(X)$ ;  $m_2 = M(Y)$

$$\mu_{m,n}(X, Y) = M((X - m_1)^m (Y - m_2)^n)$$

Cuplul discret  $\mu_{m,n}(X, Y) = \sum_{i \in I} \sum_{j \in J} (x_i - m_1)^m (y_j - m_2)^n p_{ij}$

Cuplul continuu  $\mu_{m,n}(X, Y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - m_1)^m (y - m_2)^n f(x, y) dx dy$

## §6. Covarianța (Corelație). Coeficient de corelație

6.1. Def.  $X, Y$  v.a. 1D;  $m_1 = M(X)$ ;  $m_2 = M(Y)$  (p. 109-110)

Covarianța  $\text{cov}(X, Y) = M((X - m_1)(Y - m_2))$

Obs.  $\text{cov}(X, Y) = \mu_{1,1}(X, Y)$

6.2. Formula covarianței  $\text{cov}(X, Y) = M(XY) - M(X)M(Y)$

6.3. Proprietăți ale covarianței (i)  $\text{cov}(X, Y) = \text{cov}(Y, X)$

(ii)  $\text{cov}(X, X) = M(X^2) - M^2(X) = D^2(X) = \text{Var}(X)$

(iii)  $X, Y$  independenți  $\Rightarrow M(XY) = M(X) \cdot M(Y) \Rightarrow \text{cov}(X, Y) = 0$



$$(iv). D^2(X+Y) = \text{Var}(X+Y) = D^2(X) + D^2(Y) + 2\text{cov}(X, Y)$$

$$(v) D^2(X_1 + X_2 + X_3 + \dots + X_n) = \sum_{i=1}^n D^2(X_i) + 2 \sum_{1 \leq i < j \leq n} \text{cov}(X_i, X_j)$$

6.4. Matrice de covarianță  $a_{ij} = \text{cov}(X_i, X_j) \Rightarrow$

$$\Rightarrow M(\text{cov}(X, Y)) = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{pmatrix}$$

6.5. Coefficient de corelație  $r(X, Y) = \frac{\text{cov}(X, Y)}{\sigma(X)\sigma(Y)}$ ,  
unde  $\sigma(X) = \sqrt{D^2(X)}$ ;  $\sigma(Y) = \sqrt{D^2(Y)}$

Formula de calcul

$$\left\{ \begin{array}{l} \text{discret } r(X, Y) = \frac{1}{\sigma(X)\sigma(Y)} \sum_{i \in I} \sum_{j \in J} (x_i - m_X)(y_j - m_Y) p_{ij} \\ \text{cont } r(X, Y) = \frac{1}{\sigma(X)\sigma(Y)} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - m_X)(y - m_Y) f_{X,Y}(x, y) dx dy \end{array} \right.$$

6.6. Proprietăți ale coef. corelației

$$(i) |r(X, Y)| \leq 1 \quad (-1 \leq r(X, Y) \leq 1) \quad (ii) r(X, Y) = r(Y, X)$$

$$(iii) r(X, X) = 1; \quad r(X, -X) = -1$$

$$(iv) X, Y \text{ indep.} \Rightarrow r(X, Y) = 0$$

$$(v) |r(X, Y)| = 1 \Leftrightarrow r(X, Y) \in \{-1, 1\} \Leftrightarrow X \text{ și } Y \text{ au o dependență } \left\{ \begin{array}{l} \text{lineară} \\ \text{bimantă} \end{array} \right. \Leftrightarrow$$

$$\Leftrightarrow \exists a, b \in \mathbb{R}, a \neq 0 \text{ a.i. } Y = aX + b.$$

OBS. Dacă  $r(X, Y)$  este apropiat de zero  $\Rightarrow X, Y$  sunt slab corelați  
Dacă  $|r(X, Y)|$  este apropiat de 1  $\Rightarrow X, Y$  sunt perfect corelați

## § 7. Analiza de regresie (pp. 105 - 112)

7.1. Def. Fie  $V = (X, Y)$  v.g. 2D.

(i) Funcția  $m(x) = M(Y/X) = M(Y/X=x)$  se numește funcția de regresie a v.g.  $Y$  față de v.g.  $X$ .

(ii) Curba de ecuație  $y = m(x)$  se numește curbă de regresie a v.g.  $Y$  față de v.g.  $X$ .





Se demonstrează (p. 109-110) că dreapta  $y = ax + b$  este dreapta de regresiune a v. a.  $Y: (y_1, y_2, y_3, \dots, y_n)$  faţă de v. a.  $X: (x_1, x_2, \dots, x_n)$  în condiţia  $\sum_{i=1}^n \frac{1}{n}$   $\bar{y} = M(Y) = \frac{1}{n} \sum_{i=1}^n y_i$

$$d) \quad y - \bar{y} = \frac{\text{cov}(X, Y)}{D^2(X)} (x - \bar{x}) ; \quad \bar{x} = M(X) = \frac{1}{n} \sum_{i=1}^n x_i ; \quad \bar{y} = M(Y) = \frac{1}{n} \sum_{i=1}^n y_i$$

EXEMPLU Să se determine dreapta de regresiune (aproximarea liniară prin metoda celor mai mici pătrate) corespunzătoare setului de date experimentale

| x | -1 | 0  | 2 | 3 |
|---|----|----|---|---|
| y | 1  | -1 | 2 | 5 |

R.  $A_1(-1, 1), A_2(0, -1), A_3(2, 2), A_4(3, 5)$

d:  $y = ax + b \Rightarrow$

$$\Rightarrow B_1(-1, -a+b), B_2(0, b), B_3(2, 2a+b), B_4(3, 3a+b)$$

$$g(a, b) = A_1 B_1^2 + A_2 B_2^2 + A_3 B_3^2 + A_4 B_4^2$$

$$g(a, b) = (-a+b-1)^2 + (b+1)^2 + (2a+b-2)^2 + (3a+b-5)^2 \rightarrow \min.$$

$$\frac{1}{2} \frac{\partial g}{\partial a} = (-a+b-1)(-1) + (b+1) \cdot 0 + (2a+b-2) \cdot 2 + (3a+b-5) \cdot 3 = 0$$

$$\frac{1}{2} \frac{\partial g}{\partial b} = (-a+b-1) \cdot 1 + (b+1) \cdot 1 + (2a+b-2) \cdot 1 + (3a+b-5) \cdot 1 = 0$$

$$\begin{cases} 14a + 4b = 18 \\ 4a + 4b = 7 \end{cases} \Rightarrow \begin{cases} 10a = 11 \\ a + b = 7/4 \end{cases} \Rightarrow \begin{cases} a = \frac{11}{10} \\ b = \frac{7}{4} - \frac{11}{10} = \frac{13}{20} \end{cases}$$

Deci  $a^* = \frac{11}{10}; b^* = \frac{13}{20} \Rightarrow (d^*) : y = \frac{11}{10}x + \frac{13}{20}$

Dreapta de regresiune  $y = \frac{11}{10}x + \frac{13}{20} \quad (d^*)$

$$\begin{cases} x=0 \\ y = \frac{13}{20} = 0.65 \\ x=1 \Rightarrow y = 1.25 \end{cases} \quad (0; 0.65); (1; 1.25)$$

