

Capitolul 7.

NOȚIUNI DE TEORIA ESTIMAȚIEI

§ 7.1. ESTIMAȚII CONSISTENTE. ESTIMAȚII ABSOLUT CORECTE

În numeroase aplicații ale statisticii matematice în tehnică există motive teoretice pentru a afirma că repartiția fenomenului studiat este dată de o funcție cunoscută care depinde însă de anumiți parametri necunoscuți. Așa, de pildă, dacă ζ este variabila aleatoare care reprezintă dimensiunea unei piese, iar a este valoarea standard a dimensiunii, atunci abaterile $\xi = \zeta - a$ urmează legea normală.

Prin definiție, o repartiție este *specificată* dacă este exprimată printr-o funcție dată (densitatea de repartiție sau funcția de repartiție), care conține anumiți parametri necunoscuți. În cazul exemplului de mai sus parametrii m și σ^2 ai repartiției normale sînt necunoscuți.

Pentru descrierea fenomenului cercetat este necesar să cunoaștem valorile numerice ale parametrilor. Această evaluare se face cu ajutorul unei selecții de un anumit volum, extrasă din populația statistică observată.

Prin definiție, o repartiție este *complet specificată*, dacă este exprimată printr-o funcție dată în care toți parametrii sînt cunoscuți.

Operația prin care determinăm valorile parametrilor se numește *estimarea parametrilor*.

Fie x_1, \dots, x_n o selecție de volum n dintr-o repartiție specificată. Există o infinitate de funcții de x_1, \dots, x_n care pot fi luate drept valori ale parametrilor necunoscuți. Aceste funcții se mai numesc *estimații* sau *statistici*. Problema care se pune este de a alege din această infinitate de estimații pe acelea care se apropie cel mai mult de valorile adevărate ale parametrilor necunoscuți. Estimația va fi cu atît mai bună cu cît repartiția sa se concentrează mai puternic în jurul adevăratei valori a parametrului, sau — ceea ce este același lucru — cu cît dispersia (împrăștierea) valorilor repartiției față de valoarea adevărată este mai mică.

Fie λ un parametru al populației generale (medie, dispersie etc.) și fie $f(x; \lambda)$ densitatea de repartiție a variabilei aleatoare corespunzătoare. Fie de asemenea $\bar{\lambda}_n = \bar{\lambda}_n(x_1, x_2, \dots, x_n)$ o estimație a parametrului λ . Trebuie determinată funcția $\bar{\lambda}$ astfel încît pentru diferite selecții valorile ei să fie concentrate în jurul parametrului necunoscut λ .

Estimație co-
tate către paran-
metrului λ .
Estimație ab-

vom spune că $\bar{\lambda}$
lui λ .

Prezentăm în
sau estimațiile
teoretice.

1°. *Momente*

Într-adevăr,
repartiții statist

și cum variabile

unde M , este m
verificată, teore

Urmează că

$$2^\circ. s^2 = \frac{1}{n}$$

Din legea nu

că $\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})$
buia demonstra

$$3^\circ. s'^2 = \frac{1}{n}$$

pentru $D^2(\xi)$.

Avem

Estimație consistentă. Dacă $\bar{\lambda}_n(x_1, x_2, \dots, x_n)$ converge în probabilitate către parametrul λ vom spune că $\bar{\lambda}_n$ este o estimație *consistentă* a parametrului λ .

Estimație absolut corectă. Dacă

$$M[\bar{\lambda}_n(x_1, x_2, \dots, x_n)] = \lambda, \quad (7.1.1)$$

$$\lim_{n \rightarrow \infty} D^2[\bar{\lambda}_n(x_1, x_2, \dots, x_n)] = 0$$

vom spune că $\bar{\lambda}_n(x_1, x_2, \dots, x_n)$ este o estimație *absolut corectă a parametrului* λ .

Prezentăm în continuare unele teoreme care dau estimațiile absolut corecte sau estimațiile consistente pentru parametrii cei mai uzuali ai repartițiilor teoretice.

1°. *Momentele de selecție sînt estimații absolut corecte ale momentelor teoretice.*

Într-adevăr, fie $\tilde{m}_r = \frac{1}{n} \sum_{i=1}^n x_i^r$ momentul de selecție de ordinul r al unei repartiții statistice date. Avem

$$M(\tilde{m}_r) = M\left(\frac{1}{n} \sum_{i=1}^n x_i^r\right) = \frac{1}{n} \sum_{i=1}^n M(x_i^r)$$

și cum variabilele x_i , ($i = 1, 2, \dots, n$) sînt identic repartizate

$$M(\tilde{m}_r) = \frac{1}{n} \sum_{i=1}^n \int_{-\infty}^{\infty} x^r f(x) dx = M_r,$$

unde M_r este momentul teoretic de ordinul r . Deoarece condiția (7.1.1) este verificată, teorema este demonstrată.

Urmează că *media de selecție \bar{x} este o estimație absolut corectă pentru $M(\xi)$.*

2°. $s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ este o estimație consistentă pentru $D^2(\xi)$.

Din legea numerelor mari (§ 1.13) $\bar{x} \xrightarrow{p} M(\xi)$ și $\frac{1}{n} \sum_{i=1}^n x_i^2 \xrightarrow{p} M(\xi^2)$. Urmează că $\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 \xrightarrow{p} M(\xi^2) - [M(\xi)]^2 = D^2(\xi)$, ceea ce trebuia demonstrat.

3°. $s'^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$ este o estimație consistentă absolut corectă pentru $D^2(\xi)$.

Avem

$$M(\bar{x}^2) = \frac{1}{n^2} M\left(\sum_{i=1}^n x_i^2 + 2 \sum_{i \neq j} x_i x_j\right)$$

și deoarece variabilele x_i ($i = 1, 2, \dots, n$) sînt independente și identic repartizate, rezultă

$$M(\bar{x}^2) = \frac{1}{n} M(\xi^2) + \frac{n-1}{n} [M(\xi)]^2.$$

De aici

$$M(s^2) = \frac{n-1}{n} D^2(\xi)$$

și deci

$$M(s'^2) = M\left(\frac{n}{n-1} s^2\right) = \frac{n}{n-1} M(s^2) = D^2(\xi).$$

Mai trebuie să arătăm că estimăția s'^2 este consistentă. Într-adevăr, $n/(n-1)$ poate fi considerată ca o variabilă aleatoare ce ia valoarea $n/(n-1)$ cu probabilitatea 1. Cum $n/(n-1) \xrightarrow{p} 1$, urmează că $s'^2 \xrightarrow{p} D^2(\xi)$.

Observație. În § 1.11 am văzut că media și dispersia unei variabile aleatoare Poisson sînt egale cu parametrul λ al repartiției. Pe de altă parte, teoremele 1° și 3° arată că \bar{x} și s'^2 sînt estimății consistente și absolut corecte pentru valoarea medie și dispersia unei variabile ξ . Atunci, dacă \bar{x} și s'^2 sînt determinate pe baza unei selecții dintr-o populație repartizată Poisson, trebuie să alegem una din aceste estimății pentru parametrul λ . Inegalitatea lui Cebîșev

$$P(|\bar{\lambda}_n - \lambda| \geq \varepsilon) < D^2(\bar{\lambda}_n)/\varepsilon^2,$$

unde $\bar{\lambda}_n$ este o estimăție absolut corectă pentru parametrul $\lambda > 0$ și $M(\bar{\lambda}_n^2) < \infty$, ne dă criteriul pentru alegerea estimăției; anume, vom alege acea estimăție care are dispersia cea mai mică.

Se demonstrează că *dacă*, printre toate estimățiile absolut corecte ale unui parametru λ , *există o estimăție $\bar{\lambda}_n$ a cărei dispersie*

$$D^2[\bar{\lambda}_n(x_1, \dots, x_n)] = \frac{1}{n M \left[\left(\frac{\partial \ln f(x; \lambda)}{\partial \lambda} \right)^2 \right]}, \quad (7.1.2)$$

atunci această estimăție este de dispersie minimă. În egalitatea (7.1.2) am admis că densitățile de probabilitate $f(x; \lambda)$ ale unei repartiții specificate sînt continue și au derivate parțiale de ordinul necesar în raport cu parametrul λ .

§ 7.2. ESTIMAȚII EFICIENTE

O estimăție absolut corectă $\bar{\lambda}_n(x_1, \dots, x_n)$ a parametrului λ care are dispersia minimă se numește *estimăție eficientă*.

Dacă $\bar{\lambda}_n(x_1, \dots, x_n)$ este o estimăție absolut corectă a parametrului λ , raportul

$$E_n(\bar{\lambda}_n) = \frac{1}{D^2(\bar{\lambda}_n) n M \left[\left(\frac{\partial \ln f(x; \lambda)}{\partial \lambda} \right)^2 \right]} \quad (7.2.1)$$

se numește *eficiență* $= 1$, atunci estimăm
Exemple. 1°. S

și să verificăm da
corectă și eficien
Soluție. Avem

De aici

iar

$$M \left[\left(\frac{\partial \ln f(x; \lambda)}{\partial \lambda} \right)^2 \right]$$

Apoi

deoarece variabile
repartiție ca și va

$$D^2(\lambda)$$

deoarece dispersi
Înlocuind (7.

Așadar, x est
(7.2.5)) a param
2°. Să consid

unde parametrul

se numește *eficiența* estimației $\bar{\lambda}_n$. Se observă că $0 \leq E_n(\bar{\lambda}_n) \leq 1$. Dacă $E_n(\bar{\lambda}_n) = 1$, atunci estimația este eficientă, după cum rezultă din (7.1.2) și (7.2.1).

Exemple. 1°. Să considerăm repartiția Poisson

$$f(x; \lambda) = e^{-\lambda} \frac{\lambda^x}{x!}, \quad x = 0, 1, 2, \dots$$

și să verificăm dacă media de selecție $\bar{x} = \frac{1}{n} \sum_{k=1}^n x_k$ este o estimație absolut corectă și eficientă a parametrului λ .

Soluție. Avem

$$\ln f(x; \lambda) = -\lambda + x \ln \lambda - \ln x!$$

De aici

$$\frac{\partial \ln f(x; \lambda)}{\partial \lambda} = \frac{x}{\lambda} - 1,$$

iar

$$M\left[\left(\frac{\partial \ln f(x; \lambda)}{\partial \lambda}\right)^2\right] = \frac{M(\xi^2)}{\lambda^2} - \frac{2}{\lambda} M(\xi) + 1 = \frac{\lambda^2 + \lambda}{\lambda^2} - \frac{2\lambda}{\lambda} + 1 = \frac{1}{\lambda}. \quad (7.2.2)$$

Apoi

$$M(\bar{x}) = \frac{1}{n} \sum_{k=1}^n M(\xi_k) = \frac{nM(\xi)}{n} = \frac{n\lambda}{n} = \lambda, \quad (7.2.3)$$

deoarece variabilele aleatoare ξ_k , ($1 \leq k \leq n$), care iau valorile x_k au aceeași repartiție ca și variabila Poisson ξ . Dispersia mediei de selecție este

$$D^2(\bar{x}) = \frac{1}{n^2} \sum_{k=1}^n D^2(\xi_k) = \frac{1}{n^2} \cdot nD^2(\xi) = \frac{D^2(\xi)}{n} = \frac{\lambda}{n}, \quad (7.2.4)$$

deoarece dispersia variabilei aleatoare Poisson ξ este λ .

Înlocuind (7.2.2) și (7.2.4) în (7.2.1) obținem

$$E_n(\bar{x}_n) = \frac{1}{\frac{\lambda}{n} \cdot \frac{n}{\lambda}} = 1. \quad (7.2.5)$$

Așadar, \bar{x} este o estimație absolut corectă ((7.2.3) și (7.2.4)) și eficientă ((7.2.5)) a parametrului λ .

2°. Să considerăm repartiția binomială

$$f(x; p) = p^x (1-p)^{1-x}, \quad x = 0, 1,$$

unde parametrul este $\lambda = p$, ($0 \leq p \leq 1$). Să cercetăm dacă media de selecție

$\bar{x} = \frac{1}{n} \sum x_i$ reprezintă sau nu o estimatie eficientă pentru parametrul p al repartiției.

Soluție. Pentru această repartiție știm (§ 1.11) că

$$M(\xi) = p; D^2(\xi) = p(1-p).$$

De aici deducem

$$M(\bar{x}) = p; D^2(\bar{x}) = \frac{p(1-p)}{n}.$$

Mai departe,

$$\ln f(x; p) = x \ln p + (1-x) \ln (1-p)$$

$$\frac{\partial \ln f(x; p)}{\partial p} = \frac{x}{p} - \frac{1-x}{1-p},$$

iar

$$M\left[\left(\frac{\partial \ln f(x; p)}{\partial p}\right)^2\right] = \frac{1}{p(1-p)}.$$

Prin urmare

$$E_n(\bar{x}) = 1,$$

adică \bar{x} este o estimatie eficientă pentru parametrul p .

Observație. Deoarece p reprezintă probabilitatea constantă în fiecare probă de a se realiza evenimentul care dă naștere repartiției considerate, iar media de selecție \bar{x} este frecvența relativă a apariției fenomenului în cele n probe, putem afirma că frecvența relativă este o estimatie eficientă a probabilității.

§ 7.3. ESTIMAȚII SUFICIENTE

Fie ξ o variabilă aleatoare definită pe o populație statistică și fie $f(x; \lambda)$ densitatea ei de repartiție, depinzând de parametrul necunoscut λ . Extrăgând succesiv n elemente din această colectivitate obținem rezultatele $\xi_1, \xi_2, \dots, \xi_n$, care reprezintă n variabile aleatoare, independente între ele. Dacă prima extracție dă valoarea x_1 , a doua valoarea x_2 etc., avem eșantionul de valori $\{x_1, x_2, \dots, x_n\}$. Probabilitatea apariției acestui eșantion în selecție, $P(\xi_1 = x_1, \xi_2 = x_2, \dots, \xi_n = x_n)$, adică probabilitatea ca variabila aleatoare ξ_1 să ia exact valoarea x_1 , variabila aleatoare ξ_2 să ia exact valoarea x_2 etc., se numește *funcție de verosimilitate*. Ea este o funcție reală ψ de cele n valori x_1, x_2, \dots, x_n și de parametrul λ , adică $\psi: R^n \times I \rightarrow R$, unde R^n este spațiul de selecție al valorilor x_1, x_2, \dots, x_n , iar I este intervalul în care poate lua valori parame-

trul λ . Valoarea $x_2, \dots, x_n; \lambda)$

$$\psi(x_1, x_2, \dots,$$

Deoarece pe $= x_k) = f(x_k; \lambda)$

Fie $\bar{\lambda}_n = \bar{\lambda}_n$ este de asemenea nute la întâmplare (pe care o Se arată că den de $\bar{\lambda}_n$, ci și de $g(\bar{\lambda}_n, \lambda) \geq 0$ și

rilor lui $\bar{\lambda}_n$.

Să presupun de tip continuu de $\bar{\lambda}_n$ a variab

Pe de altă p litatea

și deci, ținând

$$= g[\bar{\lambda}_n(x_1, x_2,$$

adică funcția d repartiție g a es și de estimatia

Estimațiile (7.3.4) se nun

§2. Metoda verosimilității maxime (R.A. Fisher)

2.1. Funcția de verosimilitate (Likelihood Function)
 Fie X o v.a. definită pe o populație statistică π pe $f(x; \theta)$ densitatea de probabilitate (pdf sau pmf) depinzând de parametrul necunoscut θ . Extrăgând succesiv elemente din această populație statistică, ~~de~~ ^{prin intermediul} ~~ale~~ ^{unor} variabile aleatoare de selecție X_1, X_2, \dots, X_n (independente între ele). Dacă prin extracție dă valoarea x_1 , a doua x_2, \dots , a n -a x_n , obținem eșantionul de valori $\{x_1, x_2, \dots, x_n\}$.

Funcția $l: \mathbb{R}^n \times \mathcal{T} \rightarrow \mathbb{R}$, ~~$l(x_1, x_2, \dots, x_n; \theta)$~~

$$l(x_1, x_2, \dots, x_n; \theta) = P(X_1 = x_1; X_2 = x_2; \dots; X_n = x_n)$$

se numește funcția de verosimilitate asociată v.a. X eșantionului $\{x_1, x_2, \dots, x_n\}$.

Deoarece X_1, X_2, \dots, X_n sunt v.a. independente avem:

$$l(x_1, x_2, \dots, x_n; \theta) = P(X_1 = x_1) \cdot P(X_2 = x_2) \cdot \dots \cdot P(X_n = x_n), \text{ etc.}$$

$$(1) \quad l(x; \theta) = l(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta); \quad x = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n; \quad \theta \in \mathcal{T}.$$

2.2. Funcția de log-verosimilitate

Fie funcție $L(x; \theta) = L(x_1, x_2, \dots, x_n; \theta) = \ln l(x; \theta)$, i.e.

$$(1') \quad L(x; \theta) = \ln L(x_1, x_2, \dots, x_n; \theta) = \sum_{i=1}^n \ln f(x_i; \theta); \quad x \in \mathbb{R}^n; \quad \theta \in \mathcal{T}.$$

2.3. Metoda verosimilității maxime (Maximum Likelihood Method)

Se pune problema alegerei acelei statistici $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$ a parametrului θ pentru care $l(x; \hat{\theta})$ devine maximă $\Leftrightarrow L(x; \hat{\theta})$ devine maximă.

Din punct de vedere matematic, această problemă revine la rezolvarea ecuației:

$$(2) \quad \frac{\partial l}{\partial \theta} = 0 \quad \text{sau, echivalent,}$$

$$(2') \quad \frac{\partial L}{\partial \theta} = 0 \Leftrightarrow \frac{\partial (\ln l(x; \theta))}{\partial \theta} = 0$$

Ecuația (2) sau (2') se numește ecuație de verosimilitate iar soluția sa $\hat{\theta}_M = \hat{\theta}(x_1, x_2, \dots, x_n)$ se numește estimare de verosimilitate maximă sau indicator de probabilitate maximă; prescurt estimare ML (Maximum Likelihood)

2.4. Capitol ~~univariat~~ ~~adstat~~ X repartiții multiparametrice

Dacă p.d.f (sau p.m.f) pentru X este de forma $f(x; \theta_1, \theta_2, \dots, \theta_s)$, atunci funcția de verosimilitate, respectiv de lg-verosimilitate este

$$(3) \quad l(x; \theta) = l(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_s) = \prod_{i=1}^n f(x_i; \theta) = \prod_{i=1}^n f(x_i; \theta_1, \theta_2, \dots, \theta_s)$$

$$(3') \quad \text{respectiv } L(x, \theta) = \ln(x; \theta) = \sum_{i=1}^n \ln f(x_i; \theta); \quad x = (x_1, x_2, \dots, x_n); \theta = (\theta_1, \theta_2, \dots, \theta_s)$$

Ecuațiile de verosimilitate (2) sau (2') devin sisteme de ecuații de verosimilitate:

$$(4) \quad \frac{\partial l}{\partial \theta_i} = 0; \quad 1 \leq i \leq s$$

$$(4') \quad \frac{\partial L}{\partial \theta_i} = 0; \quad 1 \leq i \leq s.$$

sau dan estimărilor de verosimilitate maximă $\hat{\theta}_i = \hat{\theta}_i(x_1, x_2, \dots, x_n); 1 \leq i \leq s$.
(estimări ML)

2.5. Observații

2.5.1. MLM furnizează estimări $\hat{\theta}$ cu proprietăți statistice pozitive, de aceea estimatori nedegrosați ai parametrilor respectivi (există excepții) Una din proprietăți importante ale MLM este următoarea:

Dacă h este o funcție reală (de o anumită regularitate) ~~atunci~~ $\hat{\theta}_M$ este un estimator de maximă verosimilitate pentru θ , atunci $h(\hat{\theta}_M)$ este un estimator de maximă verosimilitate pentru $h(\theta)$, respectiv

$h(\hat{\theta}_M) = \widehat{h(\theta)}_M$. În particular $\frac{1}{\hat{\theta}_M} = \widehat{\left(\frac{1}{\theta}\right)}_M$, adică inversul estimatorului ~~de~~ ^{ML} ~~ML~~ coincide cu ~~inversul~~ ^{LM} estimatorul ~~de~~ ^{LM} al inversului parametrului.

2.5.2. De aceea, în aplicații există două situații nefavorabile pentru MLM:

- (i) ecuația (2) sau (2'), respectiv sistemul (4) sau (4') nu are soluție. În aceste situații, se optează pentru alte metode de rezolvare, de exemplu metoda momentelor. (§3)
- (ii) Ecuația (2) sau (2') respectiv sistemul (4) sau (4') nu are soluție.

2.6. Example

2.6.1. Fie $X: \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix}$; $q=1-p$, $p \in [0,1]$.

Să se estimeze parametrul p pe baza unei selecții repetate (x_1, x_2, \dots, x_n)

R. Funcția de verosimilitate este:

$l(x_1, x_2, \dots, x_n; p) = P(X_1=x_1, X_2=x_2, \dots, X_n=x_n)$. Dacă k dintre valorile x_1, x_2, \dots, x_n sunt egale cu 1, restul de $n-k$ sunt 0, atunci:

$$l(x_1, x_2, \dots, x_n; p) = p^k q^{n-k} = p^k (1-p)^{n-k}$$

$$L(x_1, x_2, \dots, x_n; p) = k \ln p + (n-k) \ln (1-p)$$

Ecuația de verosimilitate maximă (2') este: $\frac{\partial L}{\partial p} = 0$

$$\Leftrightarrow \frac{k}{p} - \frac{n-k}{1-p} = 0 \Leftrightarrow p = \frac{k}{n} = \frac{x_1 + x_2 + \dots + x_n}{n} = \bar{x}$$

Deci medie de selecție $\bar{x} = \frac{1}{n} \sum_{k=1}^n x_k$ este o estimare de verosimilitate maximă pentru p . Se poate arăta, analog exemplului 1.10 că $e(\bar{x}) = 1$, deci \bar{x} este o estimare eficientă pentru p .

Observație Orice funcție de estimare eficientă (i.e. o estimare eficientă) a unui parametru θ verifică ecuația de verosimilitate maximă

2.6.2. Repartiția timpului de funcționare a unei lămpi electronice este dată de densitatea $f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-x/\theta} & ; x > 0 \\ 0 & ; x \leq 0 \end{cases}$ (distribuție exponențială negativă)

Fie x_1, x_2, \dots, x_n duratele de funcționare a n lămpi electronice.

(i) Să se determine estimarea $\hat{\theta}$ de verosimilitate maximă

(ii) Să se arate că $\hat{\theta}$ este o estimare ^{absolut exactă} nedegresată pentru θ .

R. (i) $l(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta) = \theta^{-n} e^{-(x_1 + \dots + x_n)/\theta}$

Funcția (2) este $\frac{\partial L}{\partial \theta} = 0 \Leftrightarrow -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n x_i = 0$, de unde

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

(ii) $M(\hat{\theta}) = M(\bar{x}) = \frac{1}{n} \cdot n\theta = \theta$, deci $\hat{\theta}$ este nedegresată

Abon depart, $M(\theta^2) = M_2(\theta) = M\left(\frac{1}{n} \sum_{i=1}^n x_i\right)^2 = \frac{1}{n} \left(\sum_{i=1}^n M(x_i^2) + 2 \sum_{i < j} M(x_i x_j) \right)$

Deci $M(x_i^2) = \frac{1}{\theta} \int_0^{\infty} t^2 e^{-t/\theta} dt = \frac{1}{\theta} \mathcal{L}\{t^2\}\left(\frac{1}{\theta}\right) = \frac{1}{\theta} \cdot \frac{2!}{\left(\frac{1}{\theta}\right)^3} \Big|_{s=1/\theta} =$
 $= \frac{1}{\theta} \cdot 2 \cdot \theta^3 = 2\theta^2$, deci $M_2(\theta) = \frac{1}{n} (2n\theta^2 + 2 \cdot \frac{n(n-1)}{2} \theta^2) = \frac{n+1}{n} \theta^2$

Atfel $D^2(\hat{\theta}) = M_2(\hat{\theta}) - M^2(\hat{\theta}) = \frac{n+1}{n} \theta^2 - \theta^2 = \frac{\theta^2}{n}$, deci

$D^2(\hat{\theta}) = \frac{\theta^2}{n} \rightarrow 0$ pentru $n \rightarrow \infty$. Atfel, $\hat{\theta} = \bar{x}$ este o estimare absolut corectă pentru parametrul θ

(iii) $I(\hat{\theta}) = n \int_{-\infty}^{\infty} \left(\frac{\partial \ln f(x; \theta)}{\partial \theta} \right)^2 f(x; \theta) dx = n \int_0^{\infty} \left(\frac{x-\theta}{\theta^2} \right)^2 \cdot \frac{1}{\theta} e^{-x/\theta} dx =$
 $= \frac{n}{\theta^5} \mathcal{L}\{(t-\theta)^2\}\left(\frac{1}{\theta}\right) = \frac{n}{\theta^5} \left(\frac{2}{\theta^3} - 2 \cdot \frac{1}{\theta^2} \cdot \theta + \theta^2 \cdot \frac{1}{\theta} \right) \Big|_{s=1/\theta} = \frac{n}{\theta^2}$, deci

$e(\hat{\theta}) = \frac{1}{I(\hat{\theta}) D^2(\hat{\theta})} = 1$, ceea ce arată că $\hat{\theta}$ este o estimare eficientă pt θ

2.6.3. Se $x = (x_1, x_2, \dots, x_n)$ o selecție dintr-o populație în care caracteristica impusă arectării este o variabilă aleatoare X de tip Gamma generalizată,

i.e. $f(x; \theta, \alpha) = \begin{cases} \frac{\theta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\theta x} & ; x > 0 \\ 0 & ; x \leq 0 \end{cases}$; unde $\theta > 0, \alpha > 0$.

(i) Să se estimeze cu MLM parametrul α și θ .

(ii) În ipoteza că timpul de funcționare a unui generator electric este caracterizat prin pdf de mai sus, și că duratele de funcționare a 3 apte generatoare sunt 100, 110, 150, 175, 185, 200, 220 ore, să se estimeze cu MLM parametrul α și θ .

R. Avem $L(x; \theta, \alpha) = \ln l(x; \theta, \alpha) = \ln \prod_{i=1}^n f(x_i; \theta, \alpha)$ deci

~~$L(x; \theta, \alpha) = \ln \frac{\theta^{n\alpha}}{(\Gamma(\alpha))^n} \left(\prod_{i=1}^n x_i^{\alpha-1} \right) \exp(-\theta \sum_{i=1}^n x_i) = \frac{n\alpha}{(\Gamma(\alpha))^n} \ln \theta - \theta \sum_{i=1}^n x_i + \ln \prod_{i=1}^n x_i^{\alpha-1}$~~

~~hiacul derivatilor de VM (41) este $\frac{\partial L}{\partial \theta} = 0$; $\frac{\partial L}{\partial \alpha} = 0$~~

~~$\Rightarrow \frac{n\alpha}{(\Gamma(\alpha))^n} \ln \theta - \theta \sum_{i=1}^n x_i + \ln \prod_{i=1}^n x_i^{\alpha-1} = 0$~~

$\Rightarrow L(x; \theta, \alpha) = n\alpha \ln \theta - n \ln \Gamma(\alpha) + \sum_{i=1}^n (\alpha-1) \ln x_i - \theta \sum_{i=1}^n x_i$

Sistemul de ecuații ~~de VM~~ (4') $\frac{\partial L}{\partial \theta} = 0$; $\frac{\partial L}{\partial \alpha} = 0$ este:

$$\begin{cases} \frac{n\alpha}{\theta} - \sum_{i=1}^n x_i = 0 \\ n \ln \theta + \sum_{i=1}^n \ln x_i - n \cdot \frac{d \ln P(\alpha)}{d\alpha} = 0 \end{cases}$$

Soluția acestui sistem nu se poate obține pe cale algebrică, de aceea se aplică metode aproximative necesare.

Dacă $\alpha \geq 2$ se poate lua $\frac{d}{d\alpha} \ln P(\alpha) \approx \ln(\alpha - \frac{1}{2}) + \frac{1}{2\alpha}(\alpha - \frac{1}{2})^{-2} = g(\alpha)$

și se definește $\hat{\alpha} = \frac{\theta}{n} \sum_{i=1}^n x_i = \theta \bar{x}$; $\hat{\theta} = (\exp g(\alpha)) \cdot \left(\prod_{k=1}^n x_k \right)^{-1/n}$; $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

deoarece $\exp(g(\alpha)) = (\alpha - \frac{1}{2}) \cdot \exp(\frac{1}{2\alpha}(\alpha - \frac{1}{2})^{-2})$, iar pentru valori mici ale lui x avem $e^x \approx 1+x$ rezultă $\exp g(\alpha) \approx \alpha - \frac{1}{2} + \frac{1}{2\alpha}(\alpha - \frac{1}{2})^{-1}$.

Atunci: ~~$\hat{\alpha} = \hat{\theta} \bar{x}$~~ $\hat{\alpha} = \hat{\theta} \bar{x}$; $\hat{\theta} = \left[\hat{\alpha} - \frac{1}{2} + \frac{1}{2\hat{\alpha}}(\hat{\alpha} - \frac{1}{2})^{-1} \right] \sqrt[n]{\frac{1}{x_1 x_2 \dots x_n}}$

(ii) $\hat{\alpha} = \hat{\theta} \cdot \bar{x} = 162,9 \hat{\theta}$; $\bar{x} = \frac{1}{7} (x_1 + x_2 + \dots + x_7)$

$$\begin{cases} \hat{\theta} = \left[162,9 \hat{\theta} - \frac{1}{2} + \frac{1}{24(162,9 \hat{\theta} - \frac{1}{2})} \right] \cdot 0,00637 \end{cases}$$

Refolosind (eventual ~~aproximativ~~) prin metode aproximative) rezultă $\hat{\theta} = 0,0891$; $\hat{\alpha} = 13,70$.

2.6.4. Fie $X = (x_1, x_2, \dots, x_n)$ un eșantion aleator (subie) relativ la distribuția normală $N(m; \sigma^2)$. Aplicând MLE, se determină parametrii estimându-se m și σ^2 .

R.: $f(x; m, \sigma^2) = \frac{1}{\sigma \sqrt{2\pi}} \exp\left(-\frac{(x-m)^2}{2\sigma^2}\right)$;

$$L(x; m, \sigma^2) = \ln \left\{ \left(\frac{1}{\sigma \sqrt{2\pi}} \right)^n \exp\left(-\sum_{i=1}^n \frac{(x_i - m)^2}{2\sigma^2}\right) \right\} \Leftrightarrow$$

$$L(x; m, \sigma^2) = -\frac{n}{2} \ln(2\pi) - n \ln \sigma - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - m)^2$$

Ecuațiile (4') ~~de VM~~ ~~de VM~~ ~~de VM~~: $\frac{\partial L}{\partial m} = 0$; $\frac{\partial L}{\partial \sigma} = 0 \Leftrightarrow$

$$\Leftrightarrow \begin{cases} \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - m) = 0 \\ -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (x_i - m)^2 = 0 \end{cases} \Leftrightarrow \begin{cases} \hat{m} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{m})^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \end{cases}$$

Observăm că în acest caz estimatorii ~~de ML~~ $\hat{\mu}$ și $\hat{\sigma}^2$ coincid cu cele ce îngerează intuitiv.

Interpretând estimatorii ML drept v.a., avem

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}; \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2, \text{ obținem}$$

$$E \hat{\mu} = \frac{1}{n} \cdot n \mu = \mu \quad E \hat{\sigma}^2 = \frac{1}{n} \left(\sum_{i=1}^n M(X_i^2) - 2 \mu \sum_{i=1}^n M(X_i) + n M(\bar{X}^2) \right) =$$

$$= \frac{1}{n} (M(X^2) \cdot n - 2 \mu M(X) + M(X^2) + (n-1) \sigma^2(X))$$

$$n \cdot E \hat{\sigma}^2 = M(X^2) = \frac{n}{n-1} D^2(X) = \frac{n}{n-1} \sigma^2 \quad (\text{similar cu Exemplul 1.4.})$$

Așfel, $\hat{\mu}$ este un estimator nedepăsat, iar $\hat{\sigma}^2$ este un estimator depăsat; deoarece $E \hat{\sigma}^2 = \frac{n}{n-1} \sigma^2 \rightarrow \sigma^2$ pentru $n \rightarrow \infty$, se spune că $\hat{\sigma}^2$ este un estimator asimptotic nedepăsat.

$$\text{De asemenea, } \text{var}(\hat{\mu}) = D^2(\hat{\mu}) = \frac{1}{n^2} \sum_{i=1}^n D^2(X_i) = \frac{1}{n} \sigma^2 =$$

$$= \frac{\sigma^2}{n} \rightarrow 0 \text{ pentru } n \rightarrow \infty.$$

deoarece $E \hat{\mu} = \mu$ și $\text{var}(\hat{\mu}) \rightarrow 0$ pentru $n \rightarrow \infty$, deducem că $\hat{\mu}$ este un estimator absolut corect.

2.6.5. Fie $x = (x_1, x_2, \dots, x_n)$ o mulțime (eșantion) într-o populație în care caracteristica de cercetare este o v.a. discretă X având ~~pdf~~ pmf (funcția de frecvență)

$$f(x; \theta) = \frac{1}{3^n} (5-2\theta)^{(3-x)(2-x)} \cdot \sqrt{(\theta-1)^{(x-1)(4-x)}}, \text{ dacă}$$

$x \in \{1, 2, 3\}$ și $f(x; \theta) = 0$, dacă $x \in N \setminus \{1, 2, 3\}$, iar parametrul $\theta \in T = [1, \frac{5}{2}]$. Să se determine estimatorul ML pentru θ .

$$\underline{R.} \quad L(x; \theta) = \ln \prod_{i=1}^n f(x_i, \theta) = \ln \left[\frac{1}{3^n} \prod_{i=1}^n (5-2\theta)^{(3-x_i)(2-x_i)} \cdot \prod_{i=1}^n (\theta-1)^{\frac{1}{2} \sum_{i=1}^n (x_i-1)(4-x_i)} \right] \Leftrightarrow$$

$$L(x, \theta) = -n \ln 3 + \frac{1}{2} \left[\sum_{i=1}^n (3-x_i)(2-x_i) \right] \ln(5-2\theta) + \frac{1}{2} \left[\sum_{i=1}^n (x_i-1)(4-x_i) \right] \ln(\theta-1).$$

$$\text{Funcția (2) este: } \frac{\partial L}{\partial \theta} = 0 \Leftrightarrow \frac{-2}{5-2\theta} \sum_{i=1}^n (6-5x_i+x_i^2) + \frac{1}{\theta-1} \sum_{i=1}^n (5x_i-4-x_i^2) = 0$$

$$\Leftrightarrow 2(\theta-1)(6n-5\sum x_i + \sum x_i^2) = (5\sum x_i - 4n - \sum x_i^2) \quad (*)$$

$$\Leftrightarrow 4n\theta = 15\sum x_i - 3\sum x_i^2 - 8n, \text{ deci}$$

$$\hat{\theta} = \hat{\theta}_{ML} = \frac{15}{4} \bar{x} - \frac{3}{4n} \sum_{i=1}^n x_i^2 - 2.$$

Să verificăm dacă $\hat{\theta}_{ML}$ este deplasat. Observăm că

$$M(X) = 1 \cdot f(1; \theta) + 2 \cdot f(2; \theta) + 3 \cdot f(3; \theta) = 1 \cdot \frac{1}{3}(5-2\theta) + 2 \cdot \frac{1}{3}(\theta-1) + 3 \cdot \frac{1}{3}(\theta-1) = \theta$$

$$M(X^2) = 1^2 f(1; \theta) + 2^2 f(2; \theta) + 3^2 f(3; \theta) = 1 \cdot \frac{5-2\theta}{3} + \frac{4(\theta-1)}{3} + \frac{9(\theta-1)}{3} =$$

$$= \frac{11\theta-8}{3}. \text{ De aici, rezultă:}$$

$$E(\hat{\theta}_{ML}) = \frac{15}{4} E(\bar{x}) - \frac{3}{4n} \sum_{i=1}^n E(x_i^2) - 2 = \frac{15}{4} \cdot \frac{1}{n} n\theta - \frac{3}{4n} \cdot n \cdot \frac{11\theta-8}{3} - 2 =$$

$$= \frac{15}{4} \theta - \frac{11\theta-8}{4} - 2 = \theta, \text{ deci } \hat{\theta}_{ML} \text{ este un estimator nedepusat}$$

$$\text{Acum, } \text{var } \hat{\theta}_{ML} = D^2(\hat{\theta}_{ML}) = \frac{15}{4} D^2(\bar{x}) - \frac{9}{16n} \sum_{i=1}^n D^2(x_i);$$

$$D^2(X) = M(X^2) - M^2(X) = \frac{11\theta-8}{3} - \theta^2; D^2(\bar{x}) = \frac{1}{n^2} \sum_{i=1}^n D^2(x_i) = \frac{1}{n^2} n D^2(X) =$$

$$= \frac{D^2(X)}{n}, \text{ deci } \text{var } \hat{\theta}_{ML} = D^2(\hat{\theta}_{ML}) = \frac{15}{4} \cdot \frac{D^2(X)}{n} - \frac{9}{16n^2} \cdot n D^2(X) =$$

$$= \frac{15 D^2(X)}{4n} - \frac{9 D^2(X)}{16n} = \frac{51}{16n} D^2(X) = \frac{51}{16n} \cdot \frac{11\theta-8-3\theta^2}{3} \rightarrow 0$$

$$\Leftrightarrow \text{var } \hat{\theta}_{ML} = D^2(\hat{\theta}_{ML}) \rightarrow 0 \text{ pentru } n \rightarrow \infty;$$

în concluzie, $\hat{\theta}_{ML}$ este un estimator absolut corect.

§3. Metoda momentelor

În situație în care rezolvarea ecuațiilor ML ⁽²⁾ sau a sistemului ML ⁽¹⁾ este dificilă sau implică metode aproximative laborioase, se poate apela la așa-zimuta metoda a momentelor pentru determinarea estimatorilor ML.

Fie X_1, X_2, \dots, X_n un eșantion statistic de v.a. identice distribuite, cu funcția de repartiție $F(x)$ necunoscută. Considerând selecție x_1, x_2, \dots, x_n de valori ale v.a. X_1, X_2, \dots, X_n , se poate defini funcția de distribuție a eșantionului (alecției)

$$\tilde{F}(x) = \begin{cases} 0, & x < x_1 \\ \frac{m}{n}, & x_m \leq x < x_{m+1}; 1 \leq m \leq n-1 \\ 1, & x \geq x_n \end{cases}$$

Din legea numerelor mari rezultă că $\tilde{F}(x) \rightarrow F(x), \forall x \in \mathbb{R}$, pentru $n \rightarrow \infty$.

Să presupunem că distribuția (probabilități) $f(x)$ depinde de parametri, $f(x) = F(x; \theta_1, \theta_2, \dots, \theta_s) = F(x; \theta)$, $\theta = (\theta_1, \theta_2, \dots, \theta_s)$; fie $m_i(\theta) = M(X_k^i)$, $1 \leq i \leq s$. Notăm cu \tilde{m}_i momentele de selecție (momentele experimentale), $\tilde{m}_i = \frac{1}{n} \sum_{k=1}^n x_k^i$, $1 \leq i \leq s$. Estimarea parametrului $\theta = (\theta_1, \theta_2, \dots, \theta_s)$ se realizează utilizând sistemul de ecuații

$$(1) \quad m_i(\theta) = \tilde{m}_i \Leftrightarrow E(X^i) = \tilde{m}_i, \quad 1 \leq i \leq s.$$

Soluția $\hat{\theta} = (\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_s)$ a sistemului (1) depinde condiția de $\tilde{m} = (\tilde{m}_1, \tilde{m}_2, \dots, \tilde{m}_s)$ și $\hat{\theta} \rightarrow \theta$ pentru $n \rightarrow \infty$ cu probabilitatea 1.

Metoda momentelor (care constă, deci, în egalarea momentelor teoretice cu momentele de selecție) furnizează în unele cazuri estimări nedegenerate (estimări nedegenerate).

Exemple

Ex. 1. Să luăm v.a. X cu $F_X(x; \delta, b) = \begin{cases} 0, & x < 0 \\ \left(\frac{x}{b}\right)^\delta, & 0 \leq x \leq b; \delta > 0, b > 0 \\ 1, & x > b \end{cases}$

Aici $\theta = (\theta_1, \theta_2)$, $\theta_1 = \delta$, $\theta_2 = b$. $f(x; \delta, b) = \frac{d}{dx} F_X(x; \delta, b) = \begin{cases} \frac{\delta}{b} \left(\frac{x}{b}\right)^{\delta-1}, & 0 \leq x \leq b \\ 0, & \text{în rest} \end{cases}$

Ob. MCM conduce la ecuația $\frac{\partial L}{\partial \theta} = 0$ care are soluție

Să aplicăm metoda momentelor

Avem $\tilde{m}_1 = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$; $\tilde{m}_2 = \frac{1}{n} \sum_{i=1}^n x_i^2$ (momentele de selecție)

Momentele teoretice sunt $m_1(\delta, b) = \int_0^b x \cdot \frac{\delta}{b} \left(\frac{x}{b}\right)^{\delta-1} \frac{1}{b} dx = \frac{\delta}{b} \frac{x^{\delta+1}}{\delta+1} \Big|_0^b = \frac{\delta b}{\delta+1}$; $m_2(\delta, b) = \int_0^b x^2 \cdot \frac{\delta}{b} \left(\frac{x}{b}\right)^{\delta-1} \frac{1}{b} dx = \frac{\delta b^2}{\delta+2}$

Sistemul (1) este: $m_1(\delta, b) = \tilde{m}_1$; $m_2(\delta, b) = \tilde{m}_2 \Leftrightarrow$

$$\Leftrightarrow \begin{cases} \delta b = \bar{x}(\delta+1) \\ (\delta+2) \sum_{i=1}^n x_i^2 = n \delta b^2 \end{cases} \Leftrightarrow \begin{cases} b = \frac{\delta+1}{\delta} \bar{x} \\ (\delta+2) \sum_{i=1}^n x_i^2 = n \delta \left(\frac{\delta+1}{\delta}\right)^2 \bar{x}^2 \end{cases} \Leftrightarrow$$

$$\Leftrightarrow \begin{cases} b = \left(1 + \frac{1}{\delta}\right) \bar{x} \\ \alpha \delta^2 + 2\alpha \delta - n \bar{x} = 0 \\ \alpha = \sum x_i^2 - \sum x_i = \sum x_i^2 - n \bar{x} > 0 \end{cases} \Leftrightarrow \begin{cases} \hat{\delta} = \sqrt{1 + n \frac{\sum x_i^2}{\bar{x}}} - 1 \\ \hat{b} = \left(1 + \frac{1}{\hat{\delta}}\right) \bar{x} \end{cases}; \text{presupunem } \bar{x} < \frac{1}{n} \sum_{i=1}^n x_i^2$$

Ex. 2. Let v.a. X on $f(x; \theta) = \begin{cases} \frac{1}{\theta} & ; 0 \leq x \leq \theta \\ 1 & ; \text{elsewhere} \end{cases} ; \theta > 0$.

deci X este o v.a. uniformă. Aici notăm că α are o singură soluție

$$m_1(\theta) = \tilde{m}_1 \Leftrightarrow \int_0^\theta x \frac{1}{\theta} dx = \frac{1}{n} \sum_{i=1}^n x_i \Leftrightarrow \frac{1}{\theta} \cdot \frac{x^2}{2} \Big|_0^\theta = \bar{x} \Leftrightarrow$$

$$\Leftrightarrow \underbrace{\hat{\theta} = 2\bar{x} = \frac{2}{n} \sum_{i=1}^n x_i}$$

Observăm că $E(\hat{\theta}) = 2 E(\bar{x}) = 2 E(x) = 2 \cdot \frac{\theta}{2} = \theta$, deci $\hat{\theta}$ este indeplănit

Alternativa $D^2(\theta) = \frac{1}{n^2} \sum_{i=1}^n D^2(x_i) \approx \frac{1}{n} D^2(X) = \frac{1}{n} (E(X^2) - E^2(X)) =$
 $= \frac{1}{n} \left(\int_0^{\theta} \frac{1}{\theta} x^2 dx - \frac{\theta^2}{4} \right) = \frac{1}{n} \left(\frac{1}{\theta} \cdot \frac{\theta^3}{3} - \frac{\theta^2}{4} \right) = \frac{\theta^2}{3n}$, deni

$$D^2(\theta) = \frac{\theta^2}{3n} \rightarrow 0 \text{ for } n \rightarrow \infty.$$

În concluzie $\hat{\theta} = 2\bar{x}$ este un estimator absolut corect.

Chromatic MCM are ~~the~~ one solution. Intv-admiss

$$L(x|\theta) = \ln \prod_{i=1}^n f(x_i; \theta) = \ln \frac{1}{\theta^n} = -n \ln \theta ; \quad 0 \leq x \leq \theta$$

$$\frac{\partial L}{\partial \theta} = -\frac{\eta}{\theta} \text{ in cubic } \frac{\partial L}{\partial \theta} = 0 \text{ in one variable.}$$

§4. Metoda intervalului de încredere (M.I.I)

M.I.1. pentru estimarea unui parametru prin determinarea unui interval micuit interval de încredere, cămă aceste îi aparține cu o probabilitate fixată. (deșur, ~~prin utilizarea mti~~ ~~stamă~~ ~~trăie~~ înșfăcit un amant risc)

Se $x = (x_1, x_2, \dots, x_n)$ o vector cu componente caracteristici X

Relativ la parametrul θ presupunem că se pot determina două funcții de selecție $\theta_1(x)$ și $\theta_2(x)$, $x = (x_1, x_2, \dots, x_n)$ a afiliației probabilității inegalității

$$\theta_1(x_1, x_2, \dots, x_n) \leq \theta \leq \theta_2(x_1, x_2, \dots, x_n)$$

non dipende da α , e dico

$$P(\theta_1(x_1, x_2, \dots, x_k) \leq \theta \leq \theta_2(x_1, x_2, \dots, x_k)) = \mathcal{I}, \text{ onde } \mathcal{I} \text{ depende de } \theta.$$

Intervalul $[\theta_1(x), \theta_2(x)]$, $x = (x_1, x_2, \dots, x_n)$, care acoperă θ cu probabilitatea δ , se numește interval de încredere; cu cât acest interval este mai mic și probabilitatea δ mai mare, cu atât avem o indicație mai precisă în legătură cu valoarea lui θ .

Exemplu Determinăm parametrul m din legea normală $N(m, \sigma^2)$

Avem $f(x; m, \sigma^2) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-m)^2}{2\sigma^2}\right)$. Îi selectăm (extragem) (santionăm)

(x_1, x_2, \dots, x_n) și $\bar{x} = \frac{1}{n}(x_1 + x_2 + \dots + x_n)$ media de selecție. Scrie că

v.a. $Y = \frac{\bar{X} - m}{\frac{\sigma}{\sqrt{n}}}$ are legea normală redusă $N(0, 1)$ cu

p.d.f. $f(x; 0, 1) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$, $x \in \mathbb{R}$.

Orice $\delta > 0$ dat $\delta \in (0, 1)$ dat, putem determina numerele α_1 și α_2

astfel încât $P(\alpha_1 \leq Y \leq \alpha_2) = \delta \Leftrightarrow \Phi(\alpha_2) - \Phi(\alpha_1) = \delta$,

unde $\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_0^x \exp\left(-\frac{t^2}{2}\right) dt$ este funcția (tabelată) a lui Laplace

Așfel avem: $\alpha_1 \leq Y \leq \alpha_2 \Leftrightarrow \alpha_1 \leq \frac{\sqrt{n}}{\sigma}(\bar{x} - m) \leq \alpha_2 \Leftrightarrow$

$\Leftrightarrow \bar{x} - \alpha_2 \cdot \frac{\sigma}{\sqrt{n}} \leq m \leq \bar{x} - \alpha_1 \cdot \frac{\sigma}{\sqrt{n}}$.

Intervalul $I = \left[\bar{x} - \alpha_2 \cdot \frac{\sigma}{\sqrt{n}}, \bar{x} - \alpha_1 \cdot \frac{\sigma}{\sqrt{n}} \right)$ este interval de încredere pentru m care acoperă parametrul m cu probabilitatea δ , i.e. $P(m \in I) = \delta$.

Dacă $\alpha_1 = -\alpha_2 = \alpha > 0$, atunci $I = \left[\bar{x} - \alpha \frac{\sigma}{\sqrt{n}}, \bar{x} + \alpha \frac{\sigma}{\sqrt{n}} \right)$ este centrat în \bar{x} și are lungimea $2 \frac{\sigma}{\sqrt{n}}$.

Numărul $1 - \delta$ reprezintă probabilitatea ca parametrul m să nu aparțină intervalului de încredere și constituie riscul asumat de corectitudine întrucât $1 - \delta$, numit și nivel de semnificație este 0,05 sau 0,01.

Observație Întrucât pentru determinarea intervalului de încredere se procedează astfel:

(i) folosind o selecție x_1, x_2, \dots, x_n se construiește o funcție de selecție (statistică), de obicei $\bar{x} = \frac{1}{n}(x_1 + x_2 + \dots + x_n)$

- (ii) În legătură cu caracteristica cercetată se introduce o v.a. Y , în care intrăm funcție de selecție de la (i) și parametrul supus estimării, astfel încât se cunoaște repartiția (pdf sau pmf) pentru Y
- (iii) Se dă o probabilitate $d \in (0, 1)$. Se determină intervalul de variație $[a_1, a_2]$ al v.a. Y astfel încât $P(Y \in [a_1, a_2]) = d$.
- (iv) Din intervalul $[a_1, a_2]$ se determină intervalul de încredere pentru parametrul supus estimării.

§ 5. Teoria estimării în sens Bayes

5.1. Funcția de risc a lui Bayes

Se $J_0(y, \mathcal{H}, \mathcal{D})$ un joc statistic, \mathcal{D} ~~multimea~~ ^{spatiul} deciziilor, \mathcal{H} spatiul observatiilor, \mathcal{T} spatiul parametrilor, \mathcal{J} multimea funcțiilor (regulilor) de decizie $D: \mathcal{H} \rightarrow \mathcal{D}$

Funcția $R: \mathcal{T} \times \mathcal{J} \rightarrow \mathbb{R}$,

$$R(\theta, D) = E L(\theta, D(X)), \quad \forall (\theta, D) \in \mathcal{T} \times \mathcal{J},$$

unde $L: \mathcal{T} \times \mathcal{D} \rightarrow \mathbb{R}$ este funcția de cost a jocului J_0 ,
se numește funcția de risc a jocului statistic J_0 (pierderea medie)

Au loc validitatea

$$R(\theta, D) = \int_{-\infty}^{\infty} L(\theta, D(x)) f_{X|\theta}(x; \theta) dx, \quad \forall (\theta, D) \in \mathcal{T} \times \mathcal{J}.$$

Aici θ se consideră variabilă aleatoare (consecutiv aleator).

De aici, validitatea de mai sus se scrie

$$R(\theta, D) = \int_{-\infty}^{\infty} L(t, D(x)) f_{X|t}(x; t) dt, \quad \forall (\theta, D) \in \mathcal{T} \times \mathcal{J},$$

unde t este valoarea luată (asumată) de v.a. θ .

5.2. Funcția de risc a lui Bayes

În condițiile din definiția 5.1., funcția de risc a lui Bayes este media riscului $R(\theta, D)$ relativ la o distribuție a priori asumată pentru θ .